PONTIFICIA UNIVERSIDAD JAVERIANA

Departamento de Ingeniería de Sistemas

Arquitectura de Software

DOCUMENTO DE ARQUITECTURA DE SOFTWARE

Plataforma IoT de Monitoreo Industrial para Infraestructura Energética

Taller 1 • Caso 9

Santiago Mesa

Camilo Peñuela

Bogotá, Colombia • 11 de marzo de 2026

1. Requerimientos

El sistema consolida la telemetría de 120.000 dispositivos IoT distribuidos en subestaciones eléctricas, plantas de generación y redes de transmisión nacionales. La plataforma procesa aproximadamente 2,4 millones de eventos por minuto (3,4 mil millones diarios), detecta anomalías críticas en menos de 3 segundos y garantiza una disponibilidad mínima del 99,95 % anual. Los requerimientos se clasifican en tres categorías: proyecto, dominio y producto.

1.1. Requerimientos de Proyecto

ID	Nombre	Descripción	Justificación
RP-01	Metodología Scrum	El equipo entrega incrementos funcionales cada dos semanas mediante sprints con revisiones y retrospectivas.	Permite responder con agilidad a cambios de requisitos en entornos industriales cambiantes.
RP-02	Arquitectura nativa en la nube	El diseño implementa microservicios en Docker orquestados con Kubernetes, aislando fallos operativos por módulo.	Evita el colapso total ante picos de alertas simultáneas; solo se reinicia el módulo afectado.
RP-03	Tecnologías de código abierto	La plataforma integra InfluxDB, Apache Kafka y Grafana; evita licencias por nodo sensor.	Escala a cientos de miles de sensores sin incremento lineal de costos de licenciamiento.
RP-04	CI/CD automatizado	Pipeline de integración y despliegue continuo con pruebas automáticas previas a cada actualización productiva.	Elimina riesgo de fallos manuales en actualizaciones de un sistema crítico 24/7.
RP-05	Pruebas de carga automatizadas	Simulación del tráfico equivalente a 120.000 sensores en entorno de pre-producción antes de cada release.	Detecta cuellos de botella antes de que ocurran en producción durante una emergencia real.
RP-06	Documentación como código	Arquitectura y decisiones técnicas documentadas en repositorios versionados junto al código fuente.	Garantiza trazabilidad de decisiones para auditorías regulatorias y nuevos integrantes del equipo.

ID	Nombre	Descripción	Justificación
RP-07	Monitoreo de infraestructura propia	La plataforma mide continuamente CPU, memoria, latencia de red y throughput de los nodos de procesamiento.	Previene saturación silenciosa que retrasaría el procesamiento de alarmas críticas de la red eléctrica.

1.2. Requerimientos de Dominio

ID	Nombre	Descripción	Justificación
RD-01	IEC 61850	Estándar de interoperabilidad para comunicaciones en subestaciones eléctricas mediante Ethernet industrial.	Garantiza que equipos de distintos fabricantes se comuniquen sin adaptadores propietarios.
RD-02	MQTT v5	Protocolo de ingesta de telemetría con mínimo consumo de ancho de banda en redes celulares rurales.	El protocolo HTTP transmitiría cabeceras pesadas que colapsan conexiones inestables en zonas remotas.
RD-03	OPC UA	Integración cifrada y segura con los sistemas SCADA legados existentes en las subestaciones.	Exponer la base de datos directamente abriría brechas críticas en la red de operación (OT).
RD-04	NERC CIP	Cumplimiento de la normativa internacional de ciberseguridad para infraestructuras eléctricas críticas.	Obligación regulatoria; el incumplimiento expone a sanciones legales y riesgo de interrupción del servicio nacional.
RD-05	IEEE 1547	Soporte al monitoreo de recursos energéticos distribuidos como paneles solares y baterías.	El estándar permite integrar generación renovable sin rediseñar la plataforma.
RD-06	PTP IEEE 1588	Sincronización de tiempo con precisión de microsegundos en todos los nodos de la red.	Corrige la desincronización de reloj en subestaciones remotas, evitando inconsistencias temporales en datos de series de tiempo.

ID	Nombre	Descripción	Justificación
RD-07	ISO 27001	Marco internacional de gestión de seguridad de la información aplicado a todos los controles de la plataforma.	Proporciona validación auditable de las medidas de seguridad para entes reguladores.

1.3. Requerimientos de Producto

ID	Nombre	Descripción	Criterio de aceptación
RF-01	Base de datos de series de tiempo	Almacenamiento de millones de lecturas por segundo con timestamp exacto mediante InfluxDB Cluster.	Escritura sostenida de 50.000 eventos/s sin degradación; consultas por rango en menos de 2 s.
RF-02	Motor de eventos en tiempo real	Detección de anomalías de voltaje, vibración, temperatura y presión con disparo de alarmas en milisegundos.	El 99,9 % de alertas críticas visibles en el panel en menos de 3 s desde el evento.
RF-03	Interfaz geoespacial	Panel visual interactivo con ubicación exacta de sensores y fallas sobre mapa nacional en tiempo real.	El operador localiza cualquier sensor en menos de 5 s de navegación en el mapa.
RF-04	Actuación remota con MFA	Apagado y reconexión remota de transformadores desde el centro de control con autenticación de dos factores.	Tiempo de actuación confirmada menor a 10 s; 0 comandos ejecutados sin segundo factor válido.
RF-05	Operación offline — Edge	El gateway local procesa alarmas críticas y almacena telemetría durante cortes de conectividad a la nube.	Cero pérdida de datos tras 24 h de desconexión; resincronización completa en menos de 15 min.
RF-06	Firmware OTA	Envío y aplicación de parches de seguridad a los sensores de forma remota sin intervención física.	100 % de nodos parcheados en menos de 24 h tras publicación de vulnerabilidad crítica.

ID	Nombre	Descripción	Criterio de aceptación
RF-07	Notificaciones omnicanal	Alertas urgentes enviadas por SMS, correo electrónico y notificaciones push a los operadores designados.	Notificación entregada en menos de 30 s desde la detección en al menos 2 canales simultáneos.
RF-08	API RESTful de exportación	Interfaz para que sistemas de terceros consuman históricos de telemetría con autenticación y rate limiting.	API disponible al 99,5 % con tiempo de respuesta menor a 3 s para consultas de hasta 1 millón de registros.

2. Usuarios

La arquitectura modela diez actores con perfiles diferenciados. El diseño aplica el principio de menor privilegio sobre cada perfil, garantizando que ningún actor pueda acceder a funciones fuera de su ámbito operativo. Se distinguen actores humanos y actores máquina (sistemas externos).

Actor	Tipo	Privilegio	Descripción funcional
Operador de Centro de Control	Humano	Visualización + Gestión de alarmas	Monitorea tableros en tiempo real y gestiona alarmas operativas. Sin permisos de configuración para evitar desconexión accidental de sensores críticos.
Ingeniero de Mantenimiento	Humano	Lectura + Registro de campo	Acceso móvil al diagnóstico de sensores in situ. Registra calibraciones y cierra incidentes físicos en campo.
Administrador TI/OT	Humano	Configuración + Control de acceso	Gestiona la red, emite certificados X.509 y actualiza firmware. Centraliza el control de acceso de los gateways industriales.
Especialista en Ciberseguridad	Humano	Auditoría + Gestión de políticas	Audita tráfico de red, gestiona políticas del WAF/IDS y bloquea nodos comprometidos sin afectar la operación eléctrica.

Actor	Tipo	Privilegio	Descripción funcional
Analista de Datos Energéticos	Humano	Lectura histórica + Análisis	Consulta réplicas de lectura para análisis predictivos pesados sin degradar el monitoreo en tiempo real.
Gerente de Operaciones	Humano	Lectura ejecutiva	Accede a dashboards ejecutivos con métricas de disponibilidad y eficiencia energética. No recibe alertas operativas menores.
Auditor de Cumplimiento	Humano	Solo lectura — Auditoría	Acceso de solo lectura a registros inmutables (WORM) para garantizar transparencia ante reguladores sin comprometer datos operativos.
Sistema SCADA Legado	Máquina	Recepción de datos consolidados	Recibe datos del nuevo sistema vía OPC UA para los paneles de control heredados no reemplazables en el corto plazo.
Sistema Meteorológico Nacional	Máquina	Provisión de datos climáticos	Suministra pronósticos vía API REST para cruzar condiciones climáticas con temperatura de transformadores y anticipar fallas térmicas.
Sistema ERP Corporativo	Máquina	Lectura de métricas de activos	Recibe métricas de vida útil de sensores (ej. SAP) para automatizar órdenes de compra de repuestos.

3. Módulos Funcionales

La arquitectura divide el sistema en cinco módulos principales alineados con los actores operativos y con los criterios de calidad de la norma ISO 25010. Cada módulo es desplegable y escalable de forma independiente sobre Kubernetes.

3.1. Descripción de Módulos

Módulo	Responsabilidad	Tecnología principal	Dependencias clave
Motor de Alertas	Detecta anomalías en tiempo real mediante reglas CEP y modelos ML. Dispara notificaciones omnicanal en menos de 3 s.	Apache Flink, Apache Kafka, scikit-learn / TensorFlow Lite	Módulo de Ingesta, Base de Datos Hot
Panel Geoespacial	Visualiza la ubicación y estado de los 120.000 sensores en mapa nacional interactivo. Gestiona alarmas activas por región.	Grafana, PostGIS, Leaflet.js, API Gateway	Motor de Alertas, Gestión de Nodos
Históricos y Analítica	Almacena telemetría a largo plazo con retención de 5 años. Provee capacidades de análisis histórico para mantenimiento predictivo.	InfluxDB Cluster, Object Storage (S3), Apache Spark	Motor de Alertas, API RESTful
Gestión de Nodos	Administra el ciclo de vida de los 120.000 sensores y gateways: registro, configuración, actualización OTA y monitoreo de salud.	Kubernetes Operator, HashiCorp Vault, CI/CD pipeline	PKI Interna, Módulo de Auditoría
Auditoría y Logs	Registra de forma inmutable todos los accesos, comandos y eventos del sistema para cumplimiento regulatorio (NERC CIP, ISO 27001).	ELK Stack, WORM Storage, Wazuh SIEM	Todos los módulos

3.2. Matriz de Trazabilidad: Actores vs. Módulos

Convenciones: **C** = Configura, **U** = Usa, **L** = Lee, — = Sin acceso.

Actor / Módulo	Motor Alertas	Panel Geo.	Históricos	Gestión Nodos	Auditoría
Operador Centro Control	U	U	L	—	—
Ing. de Mantenimiento	L	L	L	U	—
Administrador TI/OT	L	L	—	C	L
Esp. Ciberseguridad	—	—	—	C	U
Analista de Datos	—	—	U	—	—
Gerente de Operaciones	—	L	L	—	—
Auditor de Cumplimiento	—	—	—	—	L
Sistema SCADA Legado	U	—	—	—	—
Sistema ERP Corporativo	—	—	L	L	—
Sistema Meteorológico	C	—	—	—	—

3.3. Matriz de Módulos vs. Atributos ISO 25010

Niveles de exigencia técnica: **A** = Alto, **M** = Medio, **B** = Bajo.

Módulo	Efic.	Fiabil.	Segur.	Compat	Usabil.	Mant.	Portab.
Motor de Alertas	A	A	A	M	B	M	M
Panel Geoespacial	A	M	M	M	A	M	A
Históricos	A	A	M	B	B	M	B
Gestión de Nodos	M	A	A	A	M	A	A
Auditoría y Logs	M	A	A	M	B	A	B

4. Restricciones y Riesgos

El diseño arquitectónico asume limitaciones innegociables impuestas por el entorno operativo y anticipa problemas futuros que amenazan la viabilidad del sistema.

4.1. Restricciones Arquitectónicas

ID	Restricción	Descripción	Impacto arquitectónico
RC-01	Integración obligada con SCADA legado	El cliente prohíbe reemplazar los controladores físicos actuales. La nueva plataforma debe conectarse mediante OPC UA.	Obliga a implementar una capa de adaptación OPC UA y limita la frecuencia de actualización de datos heredados.
RC-02	Presupuesto limitado para licencias	El proyecto carece de fondos para licencias corporativas por sensor. Toda la pila tecnológica debe ser open-source.	Tecnologías como Oracle DB, Splunk o Azure Event Hubs quedan descartadas; la elección recae en InfluxDB, Kafka y Grafana.
RC-03	Hardware de borde con recursos limitados	Las subestaciones antiguas no tienen espacio ni refrigeración para servidores de tamaño completo. Los gateways deben operar en hardware ARM de baja potencia.	Los algoritmos de detección local deben ser ligeros; modelos ML complejos ejecutan en la nube, no en el borde.
RC-04	Retención regulatoria de 5 años	La normativa exige conservar datos operativos históricos por al menos 5 años con integridad garantizable.	Requiere estrategia de almacenamiento por niveles (hot/warm/cold) y uso de WORM storage para inmutabilidad.
RC-05	Disponibilidad 99,95 % anual	El SLA exige un máximo de 4,38 h de inactividad acumulada por año, incluyendo mantenimientos programados.	Impone arquitectura multi-zona activa-activa con failover automático y despliegues blue/green sin downtime.

4.2. Riesgos del Proyecto

ID	Riesgo	Prob.	Impacto	Plan de mitigación	Contingencia
RZ-01	Saturación en capa de ingesta por picos extremos (+60 % volumen)	Alta	Crítico	Auto-escalado horizontal en Kafka con HPA de Kubernetes basado en lag del consumer group.	Circuit breaker en gateways edge para priorizar eventos críticos y descartar telemetría no urgente.
RZ-02	Pérdida de conectividad en nodos remotos durante eventos climáticos	Alta	Alto	Edge Computing con almacenamiento local de 24 h y mecanismo Store-and-Forward con MQTT QoS 2.	Activación de enlace 4G/LTE de respaldo; alertas locales sin dependencia de nube central.
RZ-03	Inconsistencias temporales por desincronización de reloj en regiones	Media	Alto	Protocolo PTP IEEE 1588 con Grandmaster Clock por región; corrección de clock skew en Flink.	Marcas de tiempo relativas al gateway local + reconciliación post-hoc con NTP como fallback.
RZ-04	Ciberataque a infraestructura crítica (inyección de datos o comandos)	Media	Crítico	mTLS con X.509 por dispositivo, segmentación de red OT/IT, WAF, IDS/IPS y auditoría en tiempo real.	Aislamiento inmediato del nodo comprometido; activación de modo degradado con operación manual local.
RZ-05	Cuellos de botella en procesamiento streaming durante tormentas	Media	Alto	Particionado de Kafka por región geográfica; Flink con backpressure automático y ventanas de tiempo adaptativas.	Reducción dinámica de granularidad de sensores no críticos; procesamiento diferido para análisis no urgente.
RZ-06	Costos exponenciales de almacenamiento a largo plazo	Media	Medio	Política de retención en InfluxDB (90 días hot), compresión warm tier, Object Storage para cold (>1 año).	Revisión anual de política de retención; downsampling de métricas de baja prioridad después de 6 meses.

ID	Riesgo	Prob.	Impacto	Plan de mitigación	Contingencia
RZ-07	Vulneración física de gateways en subestaciones sin vigilancia	Baja	Crítico	Cifrado de disco AES-256, TPM 2.0, detección de apertura de carcasa (tamper detection), VPN site-to-site.	Revocación remota de certificados X.509 del dispositivo comprometido; reemplazo de hardware programado.

5. Atributos de Calidad según ISO 25010

La norma ISO 25010 define ocho características de calidad del producto software. La arquitectura prioriza **Eficiencia de Desempeño**, **Fiabilidad** y **Seguridad** como atributos críticos (Nivel 1) dado el contexto de infraestructura energética nacional. Los cinco restantes se clasifican como importantes (Nivel 2) y están subordinados a los pilares críticos.

Nivel	Atributo	Prioridad	Razón de priorización	Impacto operativo si se incumple
1	**Eficiencia de Desempeño**	Crítica	El sistema procesa 2,4 M de eventos/min con SLA de latencia de 3 s para alertas críticas. Cualquier degradación es inaceptable en tiempo real.	Una latencia mayor a 3 s impide detectar sobrecargas en transformadores a tiempo, causando explosiones físicas y apagones regionales.
1	**Fiabilidad**	Crítica	La red eléctrica exige monitoreo continuo 24/7/365. Un tiempo de inactividad superior a 4,38 h/año viola el SLA contractual.	La caída del sistema deja ciegos a los centros de control y retrasa la respuesta ante apagones en cascada a nivel ciudad o regional.

Nivel	Atributo	Prioridad	Razón de priorización	Impacto operativo si se incumple
1	**Seguridad**	Crítica	La ley NERC CIP obliga a proteger infraestructuras eléctricas. La plataforma es objetivo directo de actores estatales y ciberterroristas.	Una vulnerabilidad exitosa permite apagar subestaciones remotamente, paralizando hospitales, acueductos y sistemas de comunicación.
2	**Compatibilidad**	Importante	Coexistencia obligada con sistemas SCADA legados y estándares industriales IEC 61850 y OPC UA.	Sin compatibilidad, el sistema operaría en silos sin visibilidad sobre equipos heredados que representan el 80 % de la infraestructura actual.
2	**Usabilidad**	Importante	Operadores de centro de control deben actuar en segundos bajo presión. Errores de interfaz son inaceptables en emergencias.	Una interfaz confusa puede llevar a un operador a desconectar el sensor equivocado o ignorar una alarma crítica por fatiga visual.
2	**Mantenibilidad**	Importante	La arquitectura de microservicios permite actualizar módulos sin detener el monitoreo. Esencial para parches de seguridad urgentes.	Sin separación de módulos, cada actualización requiere ventana de mantenimiento total, violando el SLA de disponibilidad.
2	**Portabilidad**	Importante	El empaquetamiento en Docker/Kubernetes permite migrar entre proveedores de nube para evitar vendor lock-in regulatorio.	La dependencia de un único proveedor cloud expone la infraestructura crítica a fallos de disponibilidad del proveedor.

Nivel	Atributo	Prioridad	Razón de priorización	Impacto operativo si se incumple
2	**Adecuación Funcional**	Importante	El sistema debe capturar métricas eléctricas precisas y generar alertas correctas para los tipos de sensores del dominio energético.	Funciones incompletas generan falsos negativos (anomalías no detectadas) o falsos positivos que saturan a los operadores.

6. Escenarios de Calidad

Se definen escenarios de calidad para las subcategorías más críticas de ISO 25010, utilizando la plantilla estándar de seis elementos: **Fuente**, **Estímulo**, **Artefacto**, **Entorno**, **Respuesta** y **Medida de respuesta**.

6.1. Eficiencia de Desempeño

ESC-01 — Comportamiento temporal bajo carga extrema	
Fuente	Red completa de 120.000 sensores IoT desplegados en subestaciones nacionales.
Estímulo	Los sensores envían telemetría simultánea debido a una tormenta eléctrica que incrementa el volumen en un 60 % (hasta 3,84 M eventos/min).
Artefacto	Clúster de ingesta Kafka + Motor de procesamiento Apache Flink.
Entorno	Operación degradada por evento climático extremo; hora pico de consumo eléctrico.
Respuesta	El sistema activa auto-escalado horizontal en Kafka (nuevas particiones) y en Flink (nuevos task managers). Los eventos se encolan sin rechazo de conexiones. El motor prioriza eventos críticos sobre telemetría de baja prioridad mediante backpressure adaptativo.
Medida	El 99 % de las alertas críticas aparecen en el panel del operador en menos de 3 s desde la generación en el sensor. Throughput sostenido de al menos 3,84 M eventos/min sin degradación de latencia.

ESC-02 — Utilización de recursos en gateways edge	
Fuente	Edge Gateway ARM con 4 GB de RAM operando en subestación remota.
Estímulo	1.000 sensores locales envían datos simultáneamente durante un pico de voltaje zonal.

ESC-02 — Utilización de recursos en gateways edge	
Artefacto	Motor de reglas local en el Edge Gateway (InfluxDB local + reglas CEP simplificadas).
Entorno	Operación normal; conectividad con la nube disponible; temperatura ambiente dentro de rango operativo.
Respuesta	El gateway evalúa las reglas críticas localmente, almacena telemetría en buffer local y reenvía a la nube sin superar el 70 % de CPU ni el 80 % de RAM.
Medida	CPU promedio menor al 70 %; RAM menor al 80 %; tiempo de evaluación de reglas críticas menor a 500 ms en el dispositivo.

6.2. Fiabilidad

ESC-03 — Tolerancia a fallos — Corte de conectividad regional	
Fuente	Fenómeno climático severo (huracán o tormenta eléctrica en la Costa Caribe colombiana).
Estímulo	Se corta el enlace principal de fibra óptica entre 15 subestaciones rurales y el centro de datos regional. El enlace 4G de respaldo también cae por saturación de la red móvil.
Artefacto	Edge Gateways instalados en cada subestación afectada.
Entorno	Operación degradada — desconexión total de la nube central por más de 24 horas.
Respuesta	Los gateways continúan evaluando reglas críticas de forma autónoma, ejecutando apagados de emergencia locales si detectan sobrecarga, y almacenando telemetría en InfluxDB local. Al restaurarse la conexión, sincronizan datos mediante MQTT QoS 2 con reintentos automáticos.
Medida	Cero pérdida de datos críticos tras 24 h de desconexión. Sincronización completa con la nube en menos de 15 min tras restaurar el enlace. El operador no pierde trazabilidad histórica de ningún evento ocurrido durante la desconexión.

ESC-04 — Recuperabilidad — Fallo catastrófico del data center	
Fuente	Fallo de infraestructura eléctrica en el data center principal (zona de disponibilidad primaria).
Estímulo	Caída total de todos los servicios cloud en la zona primaria, incluyendo bases de datos, procesamiento y API gateway.
Artefacto	Arquitectura multi-zona activa-activa con replicación cross-region continua.
Entorno	Desastre total de la zona primaria; zona secundaria en estado warm standby.

ESC-04 — Recuperabilidad — Fallo catastrófico del data center	
Respuesta	El balanceador de carga global redirige automáticamente el tráfico a la zona secundaria. Kubernetes detecta la indisponibilidad y activa los pods en la zona alternativa. Los datos replicados en tiempo real garantizan consistencia.
Medida	RTO menor a 15 min. RPO menor a 30 s de datos perdidos. Disponibilidad anual resultante mayor al 99,95 %.

6.3. Seguridad

ESC-05 — Confidencialidad — Intercepción de tráfico OT	
Fuente	Atacante externo con acceso a la red de telecomunicaciones que transporta tráfico de la subestación.
Estímulo	El atacante realiza un ataque man-in-the-middle para interceptar y decodificar telemetría de la red eléctrica.
Artefacto	Canal de comunicación MQTT entre sensores/gateways y el MQTT Broker en la nube.
Entorno	Operación normal; la red de telecomunicaciones está comprometida en un tramo intermedio.
Respuesta	Todo el tráfico MQTT viaja cifrado con TLS 1.3. La autenticación mutua mTLS con certificados X.509 únicos por dispositivo impide que el atacante se identifique como un nodo legítimo. El tráfico interceptado es ilegible sin las claves privadas del dispositivo, almacenadas en el TPM 2.0.
Medida	0 % de tráfico sensible accesible en texto plano. Tiempo de detección de dispositivo con certificado inválido menor a 50 ms. El intento de conexión queda registrado en el SIEM.

ESC-06 — Integridad — Inyección de comandos maliciosos	
Fuente	Atacante que ha comprometido credenciales de un operador mediante phishing.
Estímulo	El atacante intenta enviar comandos de apagado a transformadores de alta tensión desde un dispositivo no autorizado.
Artefacto	Módulo de Gestión de Nodos — API Gateway de actuación remota.
Entorno	Operación bajo ataque activo; credenciales del operador comprometidas.

ESC-06 — Integridad — Inyección de comandos maliciosos	
Respuesta	El sistema exige autenticación multifactor (MFA) para comandos de actuación. El certificado del dispositivo del atacante no coincide con el registrado. El WAF detecta el patrón de acceso inusual (horario, geolocalización) y bloquea la sesión. El SIEM genera alerta inmediata al Especialista en Ciberseguridad.
Medida	100 % de comandos de actuación requieren MFA válido. El sistema bloquea la sesión comprometida en menos de 5 s tras detección de anomalía. El intento queda registrado con hash inmutable en el log de auditoría.

6.4. Compatibilidad

ESC-07 — Interoperabilidad con sistemas SCADA legados	
Fuente	Centro de control regional con sistema SCADA de 15 años de antigüedad.
Estímulo	El SCADA legado solicita datos consolidados de voltaje y temperatura de las subestaciones de su región en el formato propietario que entiende.
Artefacto	Capa de adaptación OPC UA del módulo de Gestión de Nodos.
Entorno	Operación normal; el sistema legado no ha sido modificado ni actualizado.
Respuesta	El adaptador OPC UA traduce los datos del formato interno de la plataforma al modelo de información IEC 61850 que el SCADA legado consume. La comunicación es bidireccional y cifrada.
Medida	100 % de los sistemas SCADA registrados reciben datos en su formato esperado. Latencia de traducción OPC UA menor a 1 s. Sin modificaciones al software legado.

6.5. Usabilidad

ESC-08 — Prevención de errores operativos bajo presión	
Fuente	Operador de Centro de Control durante un blackout regional con 200 alarmas activas simultáneas.
Estímulo	El operador debe identificar el sensor con la anomalía más crítica y ejecutar un apagado de emergencia en menos de 2 minutos.
Artefacto	Panel Geoespacial — interfaz de gestión de alarmas.

ESC-08 — Prevención de errores operativos bajo presión	
Entorno	Emergencia operativa; múltiples alarmas simultáneas; presión alta sobre el operador.
Respuesta	El panel ordena automáticamente las alarmas por criticidad y geolocalización. El mapa resalta visualmente el transformador en riesgo. Un diálogo de confirmación con countdown previene actuaciones accidentales.
Medida	El operador localiza el sensor crítico en menos de 30 s. Tasa de actuaciones accidentales (comandos sobre el nodo equivocado) menor al 0,1 %.

6.6. Mantenibilidad

ESC-09 — Modificabilidad — Actualización de módulo sin downtime	
Fuente	Equipo de desarrollo que detecta una vulnerabilidad crítica en el Motor de Alertas.
Estímulo	Se requiere desplegar un parche de seguridad en producción dentro de las 4 horas siguientes a la publicación del CVE.
Artefacto	Motor de Alertas — microservicio independiente en Kubernetes.
Entorno	Sistema en producción con monitoreo activo de 120.000 sensores.
Respuesta	El pipeline CI/CD ejecuta pruebas automáticas del parche en staging en menos de 20 min. Kubernetes realiza un rolling update del Motor de Alertas sin afectar los demás módulos. El tráfico se redirige gradualmente a las nuevas réplicas.
Medida	Tiempo total del parche (commit → producción) menor a 2 h. Cero interrupciones del monitoreo durante el despliegue. 100 % de las pruebas de regresión automáticas pasadas antes del despliegue.

6.7. Portabilidad

ESC-10 — Adaptabilidad — Migración entre proveedores cloud	
Fuente	Decisión regulatoria que exige mover la infraestructura a un proveedor cloud con sede en Colombia.
Estímulo	El equipo de infraestructura recibe la orden de migrar la plataforma completa a un nuevo proveedor cloud en un plazo de 6 meses.
Artefacto	Plataforma completa empaquetada en contenedores Docker orquestada con Kubernetes.

ESC-10 — Adaptabilidad — Migración entre proveedores cloud	
Entorno	Operación continua requerida durante la migración; sin ventana de mantenimiento total disponible.
Respuesta	La arquitectura cloud-agnostic con Kubernetes, Helm charts y Terraform permite reprovisionar el entorno en el nuevo proveedor con mínimas modificaciones. La migración de datos usa herramientas estándar de InfluxDB y PostgreSQL.
Medida	Migración completa en menos de 6 meses. Sin reescritura de lógica de negocio. Menos de 4 h de downtime total durante el proceso de migración.

6.8. Adecuación Funcional

ESC-11 — Corrección funcional — Precisión en detección de anomalías	
Fuente	Sensor de voltaje en subestación de alta tensión.
Estímulo	El sensor reporta una lectura de voltaje un 15 % por encima del umbral nominal (indicador temprano de sobrecarga antes del fallo físico).
Artefacto	Motor de Alertas — reglas CEP y modelo de scoring ML.
Entorno	Operación normal; el evento ocurre en horario de baja carga administrativa.
Respuesta	El Motor de Alertas evalúa la lectura contra las reglas de umbral configuradas y el modelo de predicción de fallo. Clasifica el evento como Alerta Crítica Nivel 1 y la envía al Operador del Centro de Control y al Ingeniero de Mantenimiento responsable de la zona.
Medida	Tasa de detección verdadera (recall) mayor al 99,5 % para anomalías de nivel crítico. Tasa de falsos positivos menor al 2 %. Clasificación correcta del nivel de criticidad en más del 98 % de los eventos.

7. Acuerdos de los Atributos de Calidad (SLA)

Los Acuerdos de Nivel de Servicio formalizan las métricas de calidad que el sistema debe cumplir de forma continua y verificable. El equipo técnico monitorea estas métricas mediante dashboards de Prometheus y Grafana, generando alertas automáticas ante desviaciones.

ID	Atributo	Métrica	Acuerdo (SLA)	Herramienta de medición
SLA-01	Eficiencia de Desempeño	Latencia de alertas críticas	El 99,9 % de las alertas críticas aparecen en el panel del operador en menos de 3 s desde la detección física en el sensor, medido de extremo a extremo incluyendo transporte y procesamiento.	Prometheus + Grafana con histogramas de latencia percentil p99.
SLA-02	Eficiencia de Desempeño	Throughput de ingesta	El sistema ingesta y procesa un mínimo de 50.000 eventos por segundo de forma sostenida. Durante picos extremos (+60 %), el throughput escala a 80.000 eventos/s sin rechazar conexiones.	Kafka Consumer Lag Monitor + Flink Dashboard.
SLA-03	Fiabilidad	Disponibilidad (Uptime)	La plataforma central mantiene una disponibilidad operativa del 99,95 % anual, equivalente a un máximo de 4,38 horas de inactividad acumulada por año, incluyendo mantenimientos programados.	Prometheus Alertmanager + Uptime Robot externo.
SLA-04	Fiabilidad	Tiempo de recuperación (RTO)	El sistema restaura la operación completa en la zona secundaria en menos de 15 minutos tras una falla catastrófica del centro de datos principal. El RPO (pérdida máxima de datos) es de 30 segundos.	Pruebas de failover trimestrales + métricas de replicación cross-region.

ID	Atributo	Métrica	Acuerdo (SLA)	Herramienta de medición
SLA-05	Fiabilidad	Integridad de datos offline	Cero pérdida de eventos críticos tras un corte de conectividad de hasta 24 horas en nodos edge. Los datos se sincronizan completamente en menos de 15 minutos al restaurar el enlace.	Mecanismo de reconciliación MQTT QoS 2 + alertas de buffer overflow en gateway.
SLA-06	Seguridad	Bloqueo de intrusiones	El sistema bloquea el 100 % de las solicitudes con certificado digital inválido o ausente en menos de 50 ms. El WAF bloquea el 99,9 % de ataques conocidos (OWASP Top 10 industrial).	Wazuh SIEM + dashboards de cortafuegos perimetral.
SLA-07	Seguridad	Tiempo de parcheo	El equipo aplica parches críticos (CVSS $\geq$ 9.0) en todos los nodos en un plazo máximo de 24 horas tras la publicación del CVE. Para severidad alta (CVSS 7.0–8.9), el plazo es 72 horas.	Pipeline CI/CD con OTA Manager + registro de versiones por dispositivo.
SLA-08	Compatibilidad	Disponibilidad OPC UA	La capa de integración con SCADA legados tiene disponibilidad del 99,9 % anual. Los datos se entregan a los sistemas heredados con latencia menor a 1 s.	Monitoring de endpoints OPC UA + alertas de desconexión de SCADA registrado.
SLA-09	Mantenibilida	Lead Time de despliegue	El tiempo desde que un commit llega a la rama principal hasta que está en producción es menor a 2 horas para parches críticos y menor a 24 horas para funcionalidades nuevas.	ArgoCD pipeline metrics + DORA dashboard en Grafana.

ID	Atributo	Métrica	Acuerdo (SLA)	Herramienta de medición
SLA-10	Almacenamiento	Retención de históricos	Los datos operativos se conservan durante un mínimo de 5 años con integridad verificable. El crecimiento proyectado de 80 TB/año se gestiona automáticamente mediante la política de niveles hot/warm/cold.	InfluxDB retention policies + alertas de capacidad de Object Storage.

8. Registros de Decisiones Arquitectónicas (ADRs)

Los ADRs documentan las decisiones estructurales más importantes de la arquitectura, incluyendo el contexto que las motivó, las alternativas consideradas y descartadas, la decisión tomada, y las consecuencias positivas y negativas resultantes.

ADR-001 — Arquitectura de Microservicios sobre Kubernetes	
Estado	Aprobado
Contexto	El sistema procesa 50.000 eventos/s de forma sostenida y sirve paneles en tiempo real a múltiples usuarios simultáneamente. Un fallo en el módulo de alertas no debe afectar la visualización del mapa geoespacial ni el módulo histórico.
Alternativas consideradas	(1) **Monolito modular**: simple de desplegar, pero un fallo en cualquier módulo tumba el sistema completo — inaceptable para el SLA de 99,95 %. (2) **SOA con ESB**: mayor overhead de comunicación y punto único de fallo en el bus. (3) **Microservicios con Kubernetes**: aislamiento de fallos, escalado independiente por módulo y gestión declarativa del estado.
Decisión	Se adopta arquitectura de microservicios empaquetados en contenedores Docker y orquestados con Kubernetes. Cada uno de los cinco módulos funcionales es un servicio independiente con su propio ciclo de despliegue.
Consecuencias (+)	Escalado independiente del Motor de Alertas sin afectar la interfaz web. Despliegues rolling update sin downtime. Aislamiento de fallos por módulo. Kubernetes HPA responde automáticamente a picos de carga.
Consecuencias (–)	Mayor complejidad operativa inicial: requiere herramientas de observabilidad distribuida (Jaeger, Prometheus), service mesh para comunicación segura entre servicios y equipos con experiencia en Kubernetes.

ADR-001 — Arquitectura de Microservicios sobre Kubernetes	
Cómo validar	Prueba de caos y carga: simular la caída del Motor de Alertas en producción controlada y verificar que los demás módulos mantienen operación. Criterio de aceptación: disponibilidad global $\geq$ 99,95 % y recuperación automática de pods en menos de 2 minutos.

ADR-002 — Edge Computing — Gateways Locales en Subestaciones	
Estado	Aprobado
Contexto	Las subestaciones rurales de Colombia experimentan cortes de Internet frecuentes durante tormentas eléctricas, precisamente cuando más se necesita el monitoreo. La red eléctrica no puede esperar a que se restaure la conectividad para ejecutar acciones de protección.
Alternativas consideradas	(1) **Cloud-only sin edge**: toda la lógica en la nube; requiere conectividad constante — inaceptable para zonas remotas. (2) **Edge con lógica mínima (solo buffer)**: almacena pero no actúa; falla ante desconexión prolongada con evento crítico activo. (3) **Edge con autonomía completa**: gateway evalúa reglas localmente, actúa y sincroniza después.
Decisión	Se instalan gateways ARM en cada subestación con InfluxDB local, motor de reglas CEP simplificado y capacidad de actuación local. Operan en modo autónomo durante desconexiones y sincronizan con la nube mediante MQTT QoS 2 al restaurar conectividad.
Consecuencias (+)	Resiliencia ante cortes de Internet. Reducción de latencia para eventos críticos locales (sin round-trip a la nube). Protección física de la subestación incluso sin conectividad.
Consecuencias (−)	Aumenta la superficie de ataque físico (dispositivos en campo sin vigilancia permanente). Requiere programa de actualización OTA robusto. El modelo de reglas en el edge debe mantenerse sincronizado con el modelo central.
Cómo validar	Ejecutar una prueba de desconexión regional de 24 horas. Criterio de aceptación: cero pérdida de eventos críticos, continuidad de alarmas locales y resincronización completa en menos de 15 minutos tras recuperar conectividad.

ADR-003 — Protocolo de Ingesta MQTT v5 con Apache Kafka	
Estado	Aprobado

ADR-003 — Protocolo de Ingesta MQTT v5 con Apache Kafka	
Contexto	La plataforma debe ingestar telemetría de 120.000 sensores simultáneos en redes celulares rurales de bajo ancho de banda (2G/3G en algunas zonas). La capa de ingesta es el punto de entrada de todo el sistema y no puede perder eventos críticos.
Alternativas consideradas	(1) **HTTP/REST**: alto overhead por cabeceras en cada mensaje; colapsa redes inestables con 120.000 dispositivos. (2) **AMQP**: más robusto que HTTP pero mayor overhead que MQTT; pensado para mensajería empresarial, no IoT a escala. (3) **MQTT v5 + Kafka**: MQTT maneja el transporte ligero con QoS garantizado; Kafka proporciona el buffer de alta durabilidad y distribución a múltiples consumidores.
Decisión	MQTT v5 como protocolo de transporte entre sensores/gateways y el broker. Apache Kafka como bus de eventos central con 24 particiones (1 por región de Colombia) y factor de replicación 3.
Consecuencias (+)	Mínimo consumo de ancho de banda. QoS 2 garantiza entrega exactly-once para eventos críticos. Kafka permite múltiples consumidores independientes (Flink, ML, auditoría) del mismo stream sin acoplamiento.
Consecuencias (–)	Requiere operar un clúster Kafka de alta disponibilidad (mínimo 3 brokers + KRaft). La combinación MQTT+Kafka agrega una capa de infraestructura adicional a monitorear y operar.
Cómo validar	Prueba de estrés de ingesta con 120.000 sensores simulados y picos del 60 %. Criterio de aceptación: throughput sostenido de al menos 50.000 eventos/s, escalamiento a 80.000 eventos/s en picos y lag de consumidores dentro del umbral operativo definido.

ADR-004 — Almacenamiento Multi-Tier (InfluxDB + Object Storage)	
Estado	Aprobado
Contexto	500 TB iniciales con crecimiento de 80 TB/año y obligación de retener datos 5 años. Los costos de mantener toda la telemetría en almacenamiento de alto rendimiento serían prohibitivos. Al mismo tiempo, el mantenimiento predictivo requiere acceso eficiente a años de históricos.

ADR-004 — Almacenamiento Multi-Tier (InfluxDB + Object Storage)	
Alternativas consideradas	(1) **PostgreSQL + TimescaleDB**: buen soporte de series de tiempo pero no optimizado para el volumen de escritura requerido (50K eventos/s). (2) **InfluxDB standalone**: óptimo para escritura pero costoso para retención a 5 años. (3) **InfluxDB (hot) + Object Storage comprimido (cold)**: separa el acceso por temperatura de datos — más eficiente en costo y rendimiento.
Decisión	Estrategia de tres niveles: InfluxDB Cluster para datos hot (90 días, acceso frecuente), Object Storage con compresión Parquet para datos warm (91 días – 1 año) y cold (1–5 años). PostgreSQL para metadatos transaccionales y datos de usuarios.
Consecuencias (+)	Reducción de costos de almacenamiento estimada en un 70 % respecto a mantener todo en InfluxDB. InfluxDB optimizado para escritura masiva de series de tiempo. Object Storage escala a petabytes sin rediseño arquitectónico.
Consecuencias (–)	Mayor complejidad operativa: dos motores de bases de datos (InfluxDB + PostgreSQL) más gestión de Object Storage. Las consultas que cruzan datos hot y cold requieren federación mediante Apache Spark.
Cómo validar	Benchmark trimestral de costo y rendimiento por tier. Criterio de aceptación: reducción de costo total de almacenamiento frente a estrategia hot-only, cumplimiento de retención de 5 años y tiempos de consulta dentro de los SLA por tipo de dato (hot/warm/cold).

ADR-005 — Autenticación Mutua mTLS con Certificados X.509 por Dispositivo	
Estado	Aprobado
Contexto	La infraestructura eléctrica es objetivo de actores estatales y grupos criminales. Una autenticación débil puede permitir inyectar datos falsos que provoquen apagados innecesarios o que se ignoren anomalías reales.
Alternativas consideradas	(1) **Usuario/contraseña**: fácil de comprometer; escala muy mal para 120.000 dispositivos. (2) **API Keys compartidas**: si una clave se compromete, todos los dispositivos que la comparten quedan expuestos. (3) **X.509 único por dispositivo con mTLS**: cada dispositivo tiene su certificado único; la revocación es quirúrgica; cumple NERC CIP.

ADR-005 — Autenticación Mutua mTLS con Certificados X.509 por Dispositivo	
Decisión	Cada dispositivo físico (sensor, gateway) recibe un certificado X.509 único emitido por la PKI interna. La comunicación usa mTLS en todos los canales. La clave privada se almacena en el TPM 2.0 del hardware, no exportable por software.
Consecuencias (+)	Revocación quirúrgica de dispositivos comprometidos sin afectar a los demás. Cumplimiento de NERC CIP e ISO 27001 control A.10.1. La clave privada en TPM impide su extracción incluso con acceso físico al dispositivo.
Consecuencias (−)	Requiere implementar y operar una PKI interna completa (CA raíz offline en HSM, CA intermedia online, OCSP responder). El aprovisionamiento inicial de 120.000 certificados es operativamente complejo y debe automatizarse.
Cómo validar	Pruebas de seguridad continuas (red team + pruebas de intrusión) y escenarios de certificados revocados. Criterio de aceptación: 100 % de conexiones sin certificado válido bloqueadas, revocación efectiva en tiempo objetivo y trazabilidad completa en SIEM.

ADR-006 — Apache Flink como Motor de Stream Processing	
Estado	Aprobado
Contexto	El SLA de detección de anomalías en menos de 3 s exige un motor de procesamiento streaming de muy baja latencia capaz de manejar 50.000 eventos/s con semántica exactly-once y manejo de eventos fuera de orden por desincronización de reloj.
Alternativas consideradas	(1) **Apache Spark Streaming** (micro-batches): latencias de 100 ms – 1 s por diseño; insuficiente para el SLA de 3 s. (2) **Apache Storm**: baja latencia pero sin soporte nativo de estado y semántica exactly-once débil. (3) **Apache Flink**: procesamiento de stream verdadero (event-driven), latencia sub-segundo, estado distribuido gestionado, soporte de event time con watermarks para corrección de eventos tardíos.
Decisión	Apache Flink como motor principal de stream processing. Se usa event time con watermarks de PTP para manejar desincronización de reloj. Las ventanas de tiempo son de 1 s, 5 s y 1 min para diferentes tipos de detección.

ADR-006 — Apache Flink como Motor de Stream Processing	
Consecuencias (+)	Latencia de procesamiento sub-segundo. Manejo nativo de eventos tardíos mediante watermarks. Semántica exactly-once para garantizar que ninguna anomalía se detecte dos veces ni se pierda. Escalado horizontal automático con Kubernetes.
Consecuencias (–)	Mayor curva de aprendizaje que Spark para el equipo. La gestión del estado distribuido requiere cuidado especial en actualizaciones de versión. El checkpointing frecuente genera overhead adicional de I/O.
Cómo validar	Pruebas de latencia y exactitud con eventos fuera de orden. Criterio de aceptación: latencia de detección p99,9 menor a 3 segundos, recuperación correcta desde checkpoints y semántica effectively-once en flujos críticos.

ADR-007 — Sincronización de Tiempo con PTP IEEE 1588	
Estado	Aprobado
Contexto	Los 120.000 sensores distribuidos en todo el país tienen relojes internos que se desincronizan con el tiempo, especialmente durante apagones y reinicios. La correlación correcta de eventos entre sensores de distintas regiones requiere timestamps precisos a nivel de microsegundos.
Alternativas consideradas	(1) **NTP**: precisión de milisegundos; insuficiente para correlacionar eventos eléctricos que ocurren en microsegundos. (2) **GPS por sensor**: precisión sub-microsegundo pero costoso para 120.000 dispositivos. (3) **PTP IEEE 1588 con Grandmaster Clock por región**: precisión de microsegundos distribuida sin GPS en cada sensor.
Decisión	Despliegue de un PTP Grandmaster Clock por región sincronizado con GPS. Los gateways edge actúan como Boundary Clocks que distribuyen la señal de tiempo a los sensores locales. Apache Flink usa los timestamps PTP como event time con watermarks adaptativos.
Consecuencias (+)	Correlación precisa de eventos de múltiples sensores con precisión de microsegundos. Eliminación de inconsistencias temporales en el análisis de apagones en cascada. Cumple el requisito de IEC 61850 para marcas de tiempo de protección.
Consecuencias (–)	Requiere hardware de red compatible con PTP (switches con hardware timestamping) en las subestaciones. El coste inicial de los Grandmaster Clocks y su infraestructura de red asociada es elevado.

ADR-007 — Sincronización de Tiempo con PTP IEEE 1588	
Cómo validar	Monitoreo continuo de offset y jitter por región. Criterio de aceptación: desincronización dentro del umbral de microsegundos definido para protección eléctrica y consistencia temporal en correlación de eventos multi-región.

9. Arquitectura de Alto Nivel (HLD)

La arquitectura se organiza en seis zonas funcionales que reflejan el recorrido completo de un evento desde el sensor físico hasta la decisión operativa del centro de control. Las zonas se comunican de forma asíncrona a través de un bus de eventos central, garantizando el desacoplamiento necesario para que cada componente escale de forma independiente. Un plano transversal de seguridad vigila todas las zonas sin interrumpir el flujo de datos.

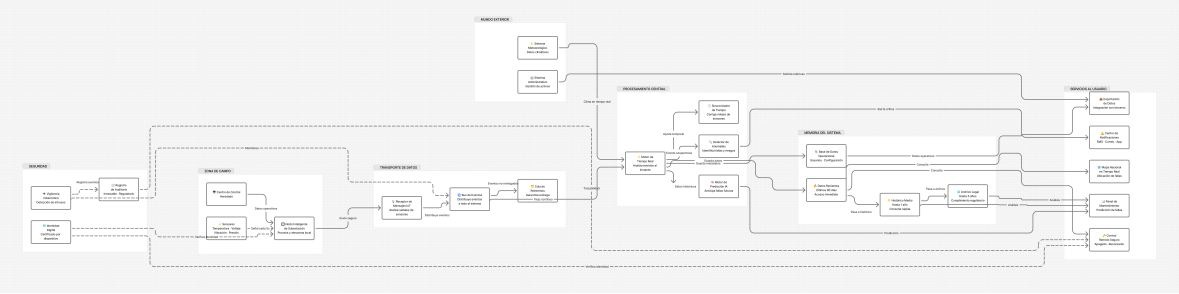

Figura 1: Arquitectura de Alto Nivel — Plataforma IoT de Monitoreo Industrial para Infraestructura Energética

9.1. Zonas de la Arquitectura

Zona	Componentes	Responsabilidad
Zona de Campo	Sensores IoT, Nodo Inteligente de Subestación, Centro de Control Heredado	Captura de telemetría física cada 5 segundos. El nodo inteligente procesa alarmas críticas localmente y almacena datos durante cortes de conectividad, garantizando autonomía operativa ante desconexiones prolongadas.

Zona	Componentes	Responsabilidad
Transporte de Datos	Receptor de Mensajes IoT, Bus de Eventos, Cola de Reintentos	Recepción masiva de eventos con entrega garantizada. El bus distribuye cada mensaje a todos los consumidores simultáneamente sin acoplamiento entre ellos. La cola de reintentos previene la pérdida de eventos críticos ante fallos transitorios.
Procesamiento Central	Motor de Tiempo Real, Detector de Anomalías, Motor de Predicción IA, Sincronizador de Tiempo	Análisis de eventos en menos de 3 segundos. Detección de anomalías mediante reglas y modelos de inteligencia artificial. Anticipación de fallas futuras para mantenimiento predictivo. Corrección de desincronización de relojes entre regiones del país.
Memoria del Sistema	Datos Recientes, Histórico Medio, Archivo Legal, Base de Datos Operacional	Almacenamiento escalonado por temperatura de datos: acceso inmediato para los últimos 90 días, consulta rápida hasta 1 año, y archivo regulatorio hasta 5 años. La base operacional gestiona usuarios, configuraciones y metadatos del sistema.
Servicios al Usuario	Mapa Nacional, Centro de Notificaciones, Control Remoto Seguro, Exportación de Datos, Panel de Mantenimiento	Cinco puntos de salida adaptados a cada perfil de usuario: visualización geoespacial en tiempo real, alertas omnicanal, actuación remota con doble verificación de identidad, integración con sistemas externos y análisis predictivo para planificación de mantenimiento.
Seguridad Transversal	Identidad Digital, Vigilancia Cibernética, Registro de Auditoría	Plano horizontal que vigila todas las zonas sin interrumpir el flujo de datos. Verifica la identidad de cada dispositivo y usuario, detecta comportamientos anómalos en tiempo real y mantiene un registro inmutable de todos los eventos del sistema para cumplimiento regulatorio.

9.2. Flujo de una Alerta Crítica

El siguiente diagrama describe el recorrido completo de un evento crítico desde su origen físico hasta la actuación del operador, con los tiempos acumulados en cada etapa para garantizar el SLA de 3 segundos.

Paso	Componente	Acción	Latencia acum.
1	Sensor IoT	Captura lectura anómala y la publica con entrega garantizada y cifrado.	0 ms
2	Nodo Inteligente	Recibe la señal, evalúa reglas críticas locales y reenvía hacia la nube.	50–100 ms
3	Receptor + Bus de Eventos	Ingesta el mensaje y lo distribuye al procesamiento central.	100–200 ms
4	Motor de Tiempo Real	Consume el evento, corrige el timestamp y evalúa ventanas temporales.	300–800 ms
5	Detector de Anomalías	Clasifica el evento como Alerta Crítica Nivel 1 y lo publica.	800 ms–1,5 s
6	Centro de Notificaciones	Envía SMS, correo y notificación push al operador responsable de la región.	1,5–2,5 s
7	Mapa Nacional	Actualiza el marcador del sensor afectado en el panel geoespacial.	2,5–3,0 s

9.3. Patrones Arquitectónicos Aplicados

Patrón	Aplicación en el sistema	Beneficio principal
Arquitectura Orientada a Eventos	Bus central como único canal de comunicación entre zonas.	Desacoplamiento total; cada zona escala sin afectar a las demás.
Separación Comando / Consulta	Escrituras de telemetría separadas de las lecturas históricas.	Los análisis pesados no degradan el monitoreo en tiempo real.
Cortocircuito	El nodo de subestación prioriza eventos críticos durante saturación.	Previene la propagación de fallos en cascada durante picos de carga.
Estrangulador	Integración gradual con centros de control heredados sin reemplazarlos.	Migración incremental sin riesgo de interrupción de sistemas existentes.

Patrón	Aplicación en el sistema	Beneficio principal
Mamparo	Particionamiento del bus por región geográfica del país.	Un fallo en una región no afecta el monitoreo de las demás.
Almacenar y Reenviar	El nodo local guarda datos durante desconexiones y los envía al restaurarse.	Garantiza integridad de datos sin pérdida ante cortes de conectividad.

10. Diagrama de Despliegue

La vista de despliegue describe dónde se ejecuta cada componente, cómo se conectan las zonas OT/IT y qué mecanismos permiten continuidad operativa ante fallos regionales.

10.1. Vista de Despliegue Implementada

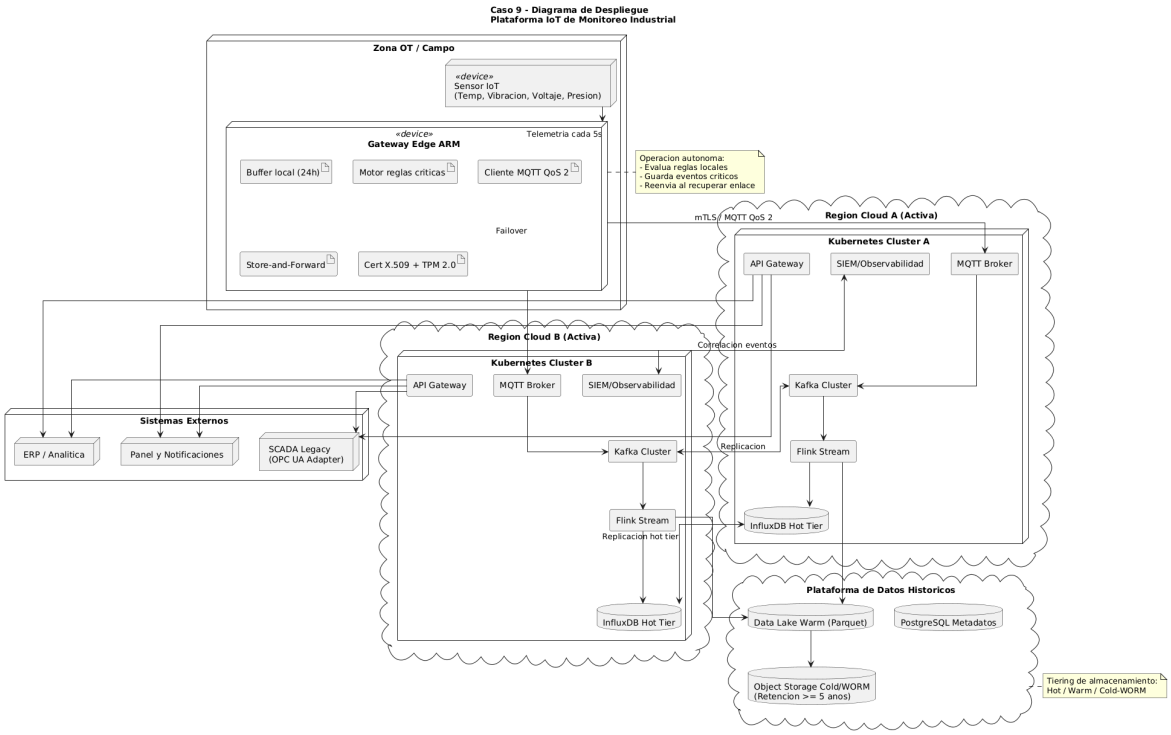

Figura 2: Diagrama de despliegue de la plataforma IoT para monitoreo industrial de infraestructura energética.

10.2. Lectura e Interpretación del Diagrama

El diagrama 2 representa una arquitectura distribuida en tres planos: **campo (OT)**, **procesamiento en nube (IT)** y **plataforma de datos históricos**. Esta separación

permite aislar responsabilidades operativas y escalar cada plano de forma independiente según su patrón de carga.

En el plano OT, los gateways edge reciben telemetría de sensores y ejecutan lógica crítica local para mantener operación segura cuando la conectividad se degrada. En el plano IT, los clústeres regionales activos-activos absorben la ingesta masiva, procesan eventos de streaming y publican alertas en tiempo real. Finalmente, el plano de datos implementa retención por niveles para equilibrar rendimiento de consulta y costo total de almacenamiento.

La integración entre regiones no solo responde a disponibilidad, sino también a objetivos de continuidad: ante caída de una región, la segunda mantiene operación sin pérdida de funciones críticas. Este comportamiento debe leerse junto con los SLA de RTO/RPO y con los ADR de tolerancia a fallos y arquitectura edge.

10.3. Decisiones de Despliegue y Justificación Técnica

Decisión	Necesidad del caso	Efecto esperado
Edge en subestaciones	Pérdida de conectividad en nodos remotos y eventos climáticos extremos	Continuidad local, protección operativa y envío diferido sin pérdida de eventos críticos.
Activa-activa multi-región	Disponibilidad anual de 99,95 % y tolerancia a fallos regionales	Alta disponibilidad, failover automático y reducción de interrupciones de servicio.
Bus de eventos desacoplado	Throughput masivo y consumidores heterogéneos (alertas, analítica, auditoría)	Escalado horizontal de ingesta y procesamiento sin acoplamiento rígido entre módulos.
Almacenamiento por niveles (hot/warm/cold)	Retención regulatoria de 5 años con crecimiento anual de volumen	Balance entre costo y rendimiento, garantizando consulta rápida reciente y archivo legal.
Seguridad transversal (PKI + SIEM)	Riesgo de ciberataques a infraestructura crítica	Autenticación fuerte, detección temprana de incidentes y trazabilidad auditada de extremo a extremo.

10.4. Nodos de Despliegue y Responsabilidades

Nodo	Componentes	Zona	Objetivo de diseño
Gateway de Subestacion	Buffer local, motor de reglas criticas, cliente MQTT con QoS 2	OT/Edge	Operacion autonoma ante desconexion y cero perdida de eventos criticos.
Cluster Kubernetes Region A	API Gateway, Broker MQTT, Kafka, Flink, servicios de negocio	IT/Cloud	Baja latencia y escalado horizontal para alta carga de eventos.
Cluster Kubernetes Region B	Misma capacidad de Region A en modo activo-activo	IT/Cloud	Tolerancia a fallos regionales con continuidad de servicio.
Plataforma de Datos Historicos	InfluxDB hot, Data Lake warm/cold, almacenamiento WORM	IT/Data	Retencion de 5 anos optimizando costo y rendimiento de consulta.
Plataforma de Seguridad y Observabilidad	PKI X.509, SIEM, WAF/IDS, trazas y metricas	Transversal	Visibilidad operativa, deteccion temprana de incidentes y cumplimiento.

11. Entregables

11.1. Documento

El documento final cumple los elementos solicitados para el caso de estudio:

Elemento requerido	Estado
Requerimientos (proyecto, dominio y producto)	Completado
Usuarios	Completado
Matriz Modulos Funcionales vs Usuarios	Completado
Restricciones y riesgos	Completado
Atributos de calidad ISO 25010 (descripcion, prioridad y clasificacion)	Completado
Escenarios de calidad (minimo 1 por subcategoria priorizada)	Completado
Acuerdos de atributos de calidad (SLA)	Completado
ADRs de la arquitectura propuesta	Completado
Arquitectura de Alto Nivel (HLD)	Completado
Diagrama de despliegue	Completado

11.2. Lecciones Aprendidas y Conclusiones

Lecciones aprendidas. La estrategia orientada a eventos y despliegue multi-region permite responder al throughput exigido sin sacrificar resiliencia. La incorporacion de capacidades edge no es opcional en entornos con conectividad intermitente. La seguridad debe disenarse de forma transversal desde el inicio para evitar retrabajos costosos.

Conclusiones. La arquitectura propuesta satisface los requisitos criticos de latencia, disponibilidad y retencion regulatoria, manteniendo control de costos mediante almacenamiento por niveles. Los ADRs y SLAs definidos ofrecen trazabilidad tecnica y criterios verificables para evolucionar la plataforma en produccion.